

DATA SCIENCE

Desentrañando el Futuro del Gas Natural en Argentina:

Análisis, Predicción y Patrones Ocultos

FUNDACIÓN
YPF

MEDIA  CHICAS



EQUIPO 5 / GAS & OIL · DATA SCIENCE



**Fabiana
Mansilla**



**Daniela
Perea**

Hidrocarburos

en Argentina

80%

Hidrocarburos

53%

Gas

4.3%

Crecimiento
2024

OBJETIVO DEL PROYECTO

Realizar un análisis exploratorio y desarrollar un modelo predictivo de la producción de gas natural en Argentina, utilizando datos históricos agregados y datos de pozos no convencionales, para identificar patrones temporales y proyectar la evolución futura de la producción a nivel nacional y por cuenca.

Nuestro Abordaje

Etapas del proyecto



Análisis Exploratorio

Entender *cómo* y *cuánto* se produce



Modelado Predictivo

Qué impulsa su evolución



Detección de Patrones

Cuáles son las tendencias y patrones de producción



01

Análisis Exploratorio

Entender *cómo* y *cuánto* se produce

01

Selección de Base de Datos



Dataset 1

Serie histórica de producción de Gas Natural
(Capítulo IV)

- Datos Temporales
- Producción por Cuenca
- Producción por Tipo de Recurso
- Volúmenes de Producción



Dataset 2


Producción de Pozos de Gas y Petróleo
No Convencional

- Identificadores.
- Volúmenes de Producción
- Volúmenes Inyectados
- Datos Geografía
- Datos de Clasificación


Evolución de la Producción de Gas Natural en Argentina




Producción Anual No Convencional: Shale, Tight y Total



Producción de Gas por Cuenca a lo Largo del Tiempo (Últimos 10 Años)





Preprocesamiento de Datos



1. Manejo de Nulos

La proporción de valores nulos representa solo: sub_tipo_recurso con 0.11% y subclasificacion con 0.30%. En pos de preservar los datos, aplicamos la estrategia de imputación por moda.



2. Escalado de Variables Numéricas (StandardScaler)

Usamos Z-score para escalar variables de producción y las variables geograficas.



3. Codificación de Variables Categóricas (OneHotEncoder)

Convertimos variables categóricas, como 'cuenca', 'provincia', 'sub_tipo_recurso', 'subclasificacion' a formato numérico utilizando OneHotEncoder.



4. Detección y Manejo de Outliers

Realizar una transformación Logarítmica y aplicar StandardScaler para Variables de Producción




02

Modelado Predictivo

Qué impulsa su evolución

Correlación con Producción de Gas



Selección de Variables



Variables a Conservar

- **Variable Objetivo:**
'produccion_gas_natural_total'
- **Variables Independientes:**
 - Características temporales
 - Indicadores de estacionalidad
 - Variable objetivo retardada.



Variables a Descartar

- Producción por cuenca
- Producción por tipo
- Producción por subtipo

02

Modelos Supervisados

Modelos de Regresión

- Regresión Lineal
- Random Forest
- SVR

Modelos para Series Temporales

- Prophet
- Arima
- Sarima

```
def predict(self, X):  
    """Predict the target variable for a given set of features X.  
    Parameters  
    X: array-like of shape (n_samples, n_features) - Input features  
    Returns  
    y: array-like of shape (n_samples,) - Predicted target values  
    """  
    # Convert X to a DataFrame with the same columns as the training data  
    X_df = pd.DataFrame(X, columns=self.feature_names_)  
    # Use the trained model to predict the target values  
    y_pred = self.model.predict(X_df)  
    return y_pred  
  
def evaluate(self, X_test, y_test):  
    """Evaluate the model's performance on a test set.  
    Parameters  
    X_test: array-like of shape (n_test, n_features) - Test features  
    y_test: array-like of shape (n_test,) - Test target values  
    Returns  
    metrics: dict - Dictionary of performance metrics  
    """  
    # Convert X_test to a DataFrame with the same columns as the training data  
    X_test_df = pd.DataFrame(X_test, columns=self.feature_names_)  
    # Use the trained model to predict the target values  
    y_pred = self.model.predict(X_test_df)  
    # Calculate the performance metrics  
    metrics = {'rmse': rmse(y_test, y_pred), 'mae': mae(y_test, y_pred),  
               'mse': mse(y_test, y_pred), 'r2': r2_score(y_test, y_pred)}  
    return metrics
```

--- ANÁLISIS DE RANKINGS ---

👤 TOP 5 - MEJOR RMSE (menor es mejor):

1° Prophet - Optimizado	RMSE: 194650.8863
2° SARIMA - Base	RMSE: 197412.2437
3° Prophet	RMSE: 210921.6267
4° Decision Tree - Base	RMSE: 218369.5055
5° XGBoost - Optimizado	RMSE: 222118.5638

📊 TOP 5 - MEJOR R² (mayor es mejor):

1° Prophet - Optimizado	R ² : 0.6387
2° SARIMA - Base	R ² : 0.6283
3° Prophet	R ² : 0.5757
4° Decision Tree - Base	R ² : 0.5452
5° XGBoost - Optimizado	R ² : 0.5295

📉 TOP 5 - MEJOR MAE (menor es mejor):

1° Prophet - Optimizado	MAE: 133252.9480
2° Prophet	MAE: 155195.5279
3° SARIMA - Base	MAE: 161664.4799
4° XGBoost - Optimizado	MAE: 175153.2111
5° XGBoost - Base	MAE: 178650.0575

📊 TOP 5 - MEJOR MAPE (%) (menor es mejor):

1° Prophet - Optimizado	MAPE (%): 3.28%
2° Prophet	MAPE (%): 3.85%
3° SARIMA - Base	MAPE (%): 3.96%
4° XGBoost - Optimizado	MAPE (%): 4.19%
5° XGBoost - Base	MAPE (%): 4.27%

Prophet (Optimizado)


Mejor RMSE (194,650)

Indica menor error cuadrático medio respecto al valor real.


Menor MAE (133,252) y MAPE (3.28%)

Implica errores absolutos bajos y alta precisión relativa.


Predicción de Producción de Gas Natural hasta 2030



Comparación de la Producción Total de Gas Natural (Primeros 4 meses de 2025)



Correlación con Producción de Gas



Selección de Variables



Variables a Conservar

- **Variable Objetivo:**
'produccion_gas_natural_total'
- **Variables Independientes:**
 - Variables Técnicas
 - Variables Geográficas
 - Variables Temporales



Variables a Descartar

- Variables por Provincia
- Variables por Pozo
- Subtipo de Recurso

🏆 TOP 5 - MEJOR RMSE (menor es mejor):			
1º Prophet - Base	Cuenca: NEUQUINA	RMSE: 0.0663	
2º Prophet - Base	Cuenca: AUSTRAL	RMSE: 0.1442	
3º RandomForest - Optimizado	Cuenca: AUSTRAL	RMSE: 0.2851	
4º XGBoost - Optimizado	Cuenca: AUSTRAL	RMSE: 0.2879	
5º DecisionTree - Optimizado	Cuenca: AUSTRAL	RMSE: 0.2985	
🏆 TOP 5 - MEJOR R2 (mayor es mejor):			
1º RandomForest - Base	Cuenca: NEUQUINA	R2: 0.8264	
2º XGBoost - Base	Cuenca: NEUQUINA	R2: 0.7379	
3º XGBoost - Base	Cuenca: AUSTRAL	R2: 0.7330	
4º DecisionTree - Base	Cuenca: NEUQUINA	R2: 0.7127	
5º RandomForest - Optimizado	Cuenca: NEUQUINA	R2: 0.7055	
🏆 TOP 5 - MEJOR MAE (menor es mejor):			
1º Prophet - Base	Cuenca: NEUQUINA	MAE: 0.0542	
2º Prophet - Base	Cuenca: AUSTRAL	MAE: 0.1430	
3º XGBoost - Optimizado	Cuenca: AUSTRAL	MAE: 0.2150	
4º RandomForest - Optimizado	Cuenca: AUSTRAL	MAE: 0.2152	
5º DecisionTree - Optimizado	Cuenca: AUSTRAL	MAE: 0.2225	
🏆 TOP 5 - MEJOR MSE (menor es mejor):			
1º Prophet - Base	Cuenca: NEUQUINA	MSE: 0.0044	
2º Prophet - Base	Cuenca: AUSTRAL	MSE: 0.0208	
3º RandomForest - Optimizado	Cuenca: AUSTRAL	MSE: 0.0813	
4º XGBoost - Optimizado	Cuenca: AUSTRAL	MSE: 0.0829	
5º DecisionTree - Optimizado	Cuenca: AUSTRAL	MSE: 0.0891	
🏆 TOP 5 - MEJOR MAPE (%) (menor es mejor):			
1º XGBoost - Base	Cuenca: AUSTRAL	MAPE (%): 5.8293%	
2º RandomForest - Base	Cuenca: AUSTRAL	MAPE (%): 6.1697%	
3º DecisionTree - Base	Cuenca: AUSTRAL	MAPE (%): 7.6673%	
4º RandomForest - Base	Cuenca: NEUQUINA	MAPE (%): 15.1268%	
5º DecisionTree - Base	Cuenca: NEUQUINA	MAPE (%): 16.7770%	

XGBoost Optimizado

Para Cuenca Austral
Muestran un balance entre bajo error y alto poder explicativo

Random Forest Optimizado

Para Cuenca Neuquina y Golfo San Jorge
Indica un mejor ajuste general y mayor capacidad de explicación de la varianza del modelo

01



Resumen Cuenca Neuquina y Cuenca Golfo San Jorge:

Periodo

2025-2030

Modelo

Random Forest Optimizado






Resumen Cuenca Austral:

Periodo

2025-2030

Modelo

XGBoost Optimizado



CONCLUSIÓN - NO CONVENCIONAL

El Futuro del Gas No Convencional



Revela una notable y consistente estacionalidad



Predictibilidad Cíclica



Muestra picos y valles anuales bien definidos, propio de un sector en auge como el de los hidrocarburos no convencionales.

CONCLUSIÓN - MODELOS SUPERVISADOS

Claves para Anticipar la Producción de Gas

- Prophet es útil para capturar tendencias estacionales y de largo plazo
- La predicción de la producción futura sigue una tendencia creciente pero más progresiva.
- Predicciones estables y consolidación de los hidrocarburos no convencionales.



03

Detección de Patrones

Cuáles son las tendencias y patrones de producción

Selección de Variables



Variables a Conservar

- **Producción por Cuenca**
- **Producción por Subtipo de Gas**
- **Variables Temporales**



Variables a Descartar

- **Producción de Gas Total**
- **Producción por Día**
- **Producción por Tipo de Gas**

K-Means



Selección de la cantidad de Clusters

**Método del Codo
(Elbow Method)**

K=3 o K=4

**Coeficiente de Silueta
(Silhouette Score)**

K=2 (0.282)



DBSCAN

Selección de la cantidad de Clusters


eps (épsilon):

1.6 y 1.7. Por lo que elegimos un valor como 1.65 para empezar.

min_samples


(puntos mínimos):

3 dado que el gráfico es para el 2do vecino más cercano.




Clustering

Clusters K-Means de Producción de Gas (Dataset1) - PCA 2D



Clusters DBSCAN de Producción de Gas (Dataset1) - PCA 2D



Selección de Variables



Variables a Conservar

- Variables de Producción
- Variables Geográficas
- Variables Categóricas



Variables a Descartar

- Variables de Identificación
- Observaciones

K-Means


Selección de la cantidad de Clusters

**Método del Codo
(Elbow Method)**

K=3 o K=4




**Coefficiente de Silueta
(Silhouette Score)**

K=2 (0.53147006)



KMEANS, DBSCAN y GMM

Clustering



CONCLUSIÓN - MODELOS NO SUPERVISADOS

Insights de los Modelos No Supervisados

El análisis con modelos no supervisados revela una transición estructural en la industria:



Dataset 1

- Cambio desde la producción convencional a la no convencional (shale y tight gas), con Neuquén como protagonista.
- K-Means identifica la transición global
- DBSCAN revela fases intermedias y micro-patrones temporales.



Dataset 2

- La Cuenca Neuquina alberga los pozos más productivos, principalmente en desarrollo y con alto contenido de gas.
- Hay zonas con producción mixta y diversa en Río Negro, Santa Cruz y Mendoza.
- La detección de outliers por parte de DBSCAN subraya la importancia de investigar pozos con comportamiento anómalo, tanto para corregir errores como para detectar nuevas oportunidades.

03

Conclusión del Clustering

Los pozos no convencionales de Argentina pueden clasificarse en grupos bien definidos según su productividad y ubicación. Esto permite:

- Entender mejor los tipos de activos disponibles
- Analizar sus características técnicas
- Tomar decisiones estratégicas o de inversión más informadas

La elección del algoritmo depende del objetivo del análisis:

- K-Means y GMM son útiles para una visión general o estratégica
- DBSCAN es ideal para análisis detallados y detección de anomalías



04

Conclusiones

CONCLUSIÓN FINAL

Conclusiones y Mirada al Futuro

- Comprensión integral de la producción de Gas en Argentina
- Confirmamos el crecimiento del gas no convencional y el rol central de la Cuenca Neuquina.
- Demostramos que los modelos predictivos son una herramienta clave para anticipar el futuro de la producción
- Los modelos no supervisados ofrecen una visión estratégica y la capacidad de detectar anomalías cruciales
- Los insights nos permiten optimizar inversiones, planificar infraestructura y asegurar la soberanía energética

DOCUMENTACIÓN



**Fabiana
Mansilla**

[Repositorio →](#)



**Daniela
Perea**

[Repositorio →](#)



iMuchas Gracias!